WeiSQL AI 项目状态报告

2026-10-31 · 仓库 HEAD 2b6dd7c · 321 个自动化测试 · 尚未发布 npm

1. 一句话状态

工程原型。Manifest V1 与数据包格式稳定，五个包共 321 个自动化测试，CI 覆盖构建、类型、测试与发布元数据；精确检索、ANN、全文、融合、RAG、单文件容器与浏览器 SQL 均有实现与实测数字。尚未发布 npm 包，也没有任何未经测量的性能承诺。

维度	状态
测试	321 个全绿（SDK 208 / DuckDB 24 / WASM 38 / USearch 13 / CLI 38）
CI	GitHub Actions：Ubuntu + Windows 行为闸门，另有派生索引、容器与 bench:wasm 冒烟作业
许可证	Apache-2.0（根目录与每个包内各一份）
发布	未发布 npm 包（缺组织与访问令牌）
实测	精确向量、ANN（含分布对照）、全文（含体积拆分）、浏览器一致性、DuckDB-Wasm 物化

2. 能力矩阵

能力	实现	测试	文档	实测
Manifest V1 校验（L1/L2）	✓	✓	✓	—
L3 资源完整性（尺寸 + SHA-256）	✓	✓	✓	✓
L4 Parquet 内容校验（CLI --l4）	✓	✓	✓	✓
HTTP / Node 文件 Reader	✓	✓	✓	✓
有界 LRU 缓存 + 请求合并	✓	✓	✓	—
Runtime 生命周期与能力报告	✓	✓	✓	—
精确向量检索	✓	✓	✓	129–152 ms p50 @100k×128
Hybrid 过滤两策略（等值/IN/范围/日期）	✓	✓	✓	—
DuckDB 只读 SQL（memory / lazy）	✓	✓	✓	—
DuckDB-Wasm 浏览器 SQL（含只读 CTE）	✓	✓ + 探针	✓	open() 1.37–1.70 s，查询 < 50 ms
USearch ANN（持久化 / 现场构建）	✓	✓	✓	0.385–0.740 Recall@10
ANN 后过滤（显式可选）	✓	✓	✓	—
全文检索 BM25	✓	✓	✓	p50 ≈10.5 ms @100k 文档
RRF 融合	✓	✓	✓	—
RAG 证据组装	✓	✓	✓	端到端
.wsql 单文件容器（pack/validate/unpack/流式）	✓	✓	✓	3.6 KB 包往返
Manifest Ed25519 签名（多签 / 轮换 / root 授权）	✓	✓	✓	篡改、信任固定与有效期均拒绝

能力	实现	测试	文档	实测
浏览器路径（Chromium）	✓	探针	✓	与 Node 逐字段一致
发布前检查 + Apache-2.0	✓	—	✓	✓
CSV/JSON → Parquet 转换工具	✓	✓	✓	✓

3. 包与依赖

包	版本	运行时依赖
@weisql/sdk	0.1.0	无
@weisql/duckdb-adapter	0.1.0	@duckdb/node-api 2.0.0-r.1
@weisql/duckdb-wasm-adapter	0.1.0	@duckdb/duckdb-wasm 1.32.0
@weisql/usearch-adapter	0.1.0	usearch 2.26.5
@weisql/cli	0.1.0	@weisql/sdk

依赖方向单向，下游对 SDK 使用 caret 范围，由 release:check 强制校验。

4. 测试与 CI

包	测试数	覆盖重点
@weisql/sdk	208	校验、Reader、缓存、Builder、精确/融合/RAG、容器、随机输入错误契约、Adapter 契约
@weisql/duckdb-adapter	24	只读边界、参数绑定、两种表加载、两层字节预算、取消
@weisql/duckdb-wasm-adapter	38	关键字白名单、CTE 分类、值映射、两层预算、取消、错误契约、真实 WASM 集成
@weisql/usearch-adapter	13	度量映射、持久化索引、后过滤、生命周期
@weisql/cli	38	校验退出码、--json、pack、unpack、容器校验、--l4
合计	321	

- verify 作业：Ubuntu + Windows 矩阵，npm ci → build → typecheck → test → release:check → 示例包校验。
- derived 作业：fixture 可复现性（重生成后 git status 必须为空）→ 构建文本/ANN 索引并校验 → 打包容器 → 解包后再次校验 → bench:wasm 冒烟（1k 行物化）。
- probe:* 与完整 bench 不在 CI 内：需要 Chromium / Python / 稳定机器，因此浏览器与性能结论必须在本地复现并注明环境。

5. 全部实测数字

指标	数值	条件	边界
精确检索 p50	129–152 ms	100k × 128，20 查询	单机、热页缓存
精确检索 I/O	51.2 MB/查询	同上	未做列裁剪
ANN 加速	≈9.5×	100k × 128，expansionSearch=512	合成数据
ANN Recall@10	0.385–0.740	均匀 0.735；紧聚类 0.385	强依赖数据分布
ANN 索引构建	2.7–15.2 s	同上	构建时间随分布变化
过滤查询（窄过滤）	p50 17.1 ms	100k 行，尾部 1000 行	反向索引把 ID

指标	数值	条件	边界
			Map 读取从 4.0 MB 降到 480 B
量化（合成，成簇）	f16 −39% 无损 / i8 −58% 掉 9.5 点	50k × 128，64 簇	提高 expansion 不能恢复 i8；真实语料未测
全文索引体积	74.2 MB	100k 文档、5000 词项、50 tokens/文档	其中正文 33.1 MB
全文查询 p50	10.2–10.8 ms	同上	固定开销 ≈8 ms + 每命中随机读
全文索引构建	4.5 s	同上	含读取 Parquet 文本列
浏览器一致性	8 向量 + 5 文本 + 9 SQL + RAG + 容器	Chromium 1248 vs Node 24	3 条记录、2 维，不能外推
DuckDB-Wasm 物化 500k 行	298 ms，RSS ~+76 MB	18.8 MB Parquet，Node 内同一 WASM	约 4× Parquet；浏览器未测
浏览器流式读取	100k/1M/5M：113/1,058/6,784 ms，首行 7–15 ms	Chromium 1248，sqlStream(range())	单次运行、合成数据
浏览器 SQL 取消	202 ms 查询 → 51 ms 返回	abort 于 50 ms	引擎未停（engineMayStillRun）

5.1 ANN 召回与数据分布

分布（100k × 128，Top-10，expansionSearch=512）	Recall@10 均值	最低
均匀随机	0.735	0.400
100 簇，spread 1.0	0.740	0.100
100 簇，spread 0.35	0.685	0.000
10 簇，spread 0.35	0.590	0.000
100 簇，spread 0.1	0.385	0.000
100 簇，spread 0.1，expansionSearch=2048	0.760	0.000

结论：召回数字必须连同分布与规模一起报告。均匀随机并不是 HNSW 最不利的情形——这一点曾被写入 ADR-030，已在 ADR-043 中用上表数据推翻。

6. 未实现与未验证

6.1 外部条件阻塞

项	阻塞原因
npm 发布	缺少组织与访问令牌；LICENSE 已确定为 Apache-2.0
真实数据集 Recall@K	需要真实 embedding 语料
多机 / 冷缓存基准	需要第二台机器与清缓存手段
真实 CDN / CORS 验收	需要实际部署环境

6.2 设计未定或明确不做

项	状态
ANN 过滤的完整性保证	只有显式后过滤，可能少于 topK，已在诊断中标注
同主版本内的索引格式变化	只按主版本判定，无法探测其内部变化
.wsql 压缩算法协商	目前只有 gzip；brotli 需要新版本号
JSON 等值过滤	需要规范化形式，当前明确拒绝
融合质量需要相关性标注	k 只做了稳定性测量，未回答哪个 k 排序更好
时间戳与嵌套列的源数据推断	转换工具只覆盖标量类型
中文分词	CJK 逐字，精度换可预测性
浏览器 SQL 参数类型	JSON 绑定；Date、二进制与超范围 bigint 明确拒绝
SQL 结果规模	maxRows 超限硬失败；sqlStream() 提供增量交付，db.sql() 仍一次性返回
浏览器大表与冷启动	只测了 Node 内的同一 WASM 构建（500k 行），浏览器内存与 34 MB 首载未测
COI / 多线程	已试不可用：parquet 扩展与共享内存 ABI 不兼容（ADR-063）

7. 关键决策

完整 70 条记录见仓库 docs/DECISION_LOG.md；下表列出与外部读者最相关的决策。

ADR	决策
016	Manifest V1 语义与约束
022	精确优先，ANN 必须自报 exact: false
026	基准装置是测量设备，不是性能承诺
028	USearch 度量映射经实测校准
029	索引参数进 Manifest，缺参数拒绝加载
030 / 043	ANN 召回必须按分布报告（043 推翻 030 的「均匀最差」判断）
032 / 033	全文索引格式、ID Map 与排序规则
035	融合用 RRF，只用排名
036	RAG 只做证据组装，不调用模型
037	ANN 过滤只提供显式后过滤
039	.wsql 不压缩、整文件入内存
040 / 044 / 045	Apache-2.0 每包自带许可证；容器防穿越；不可信输入错误契约
057	Builder 在构建时签名，发布链路少一步补签
065 / 066	浏览器 SQL 用 DuckDB-Wasm、扩展同源自托管；066 用 tokenizer 支持只读 CTE
063 / 064	COI 多线程因扩展不兼容不采用；取消只承诺立即停止等待
067	物化预算分单表与整包两层，且在建库前检查

8. 发布就绪度

检查项	状态
测试 / 类型 / 构建	✓ 321 测试，typecheck 通过
打包内容	✓ 仅 dist/ + README + LICENSE，无 src/test 泄漏
依赖范围	✓ caret 且跟踪本地版本

检查项	状态
许可证	✓ Apache-2.0（根 + 每包）
CI	✓ 双平台行为闸门
npm 组织与令牌	未完成
多机基准	未完成

结论：技术上可发布，行政上未就绪。

9. 建议的下一步

1. 配置 npm 令牌 → npm publish --dry-run 核对五个包 → 正式发布。

2. 在真实 embedding 数据上测 Recall@K，替换第 5.1 节的合成数字。

3. 补齐 SQL Adapter 的共享契约测试，覆盖 Node 与 DuckDB-Wasm 两个实现。

4. 为 db.sql 增加行数上限或流式返回，避免大结果把浏览器打爆。

5. 第二台机器复现基准，并在真实 CDN 上验收 CORS / Range / 缓存。

6. 视需要再做压缩算法协商或源数据的时间戳推断。